

RELATÓRIO FINAL DE EXPERIÊNCIAS — REDES NEURAIS

Neural Network Moon Project • Task NNPROJ-12 • Data: 17/09/2026

Autor: Pedro Rodrigues • Colaboradores: Helton Soares, Luciana Almeida • Revisão: Daniela Amaro

1. Objetivo do Projeto

O objetivo central deste trabalho não é encontrar a melhor arquitetura de rede neural possível, mas sim realizar um estudo científico controlado sobre como alterações estruturais e de dados afetam o processo de aprendizagem e a capacidade de generalização de uma rede neural artificial em problemas de classificação binária não linearmente separáveis.

2. Problema de Classificação Binária

Classificação binária consiste em prever uma entre duas classes possíveis (0 ou 1) a partir de atributos de entrada (duas coordenadas (x_1, x_2)). Foram utilizados dois conjuntos sintéticos:

- `make_moons`: 500 amostras formando duas meias-luas entrelaçadas (ruído 0.15).
- `make_circles`: 500 amostras formando dois círculos concêntricos (ruído 0.15, fator padrão 0.8).

Ambos os padrões são não lineares: não é possível separar as classes por uma única reta, exigindo redes com camadas ocultas e funções de ativação não lineares.

3. Descrição da Baseline E01

A baseline E01 adota 2 camadas ocultas com 8 neurónios cada, ativação tanh, saída sigmoid, otimizador Adam, loss `binary_crossentropy`, 100 épocas e batch size 16. O split é 75% treino (375 amostras) e 25% teste (125 amostras), com `StandardScaler` ajustado exclusivamente no conjunto de treino. Atingiu accuracy de 98.40% e loss de 0.0853 com 105 parâmetros.

4. Regra Científica: 'Uma Variável de Cada Vez'

Para garantir validade causal, cada experiência subsequente (E02 a E05) altera exatamente um único elemento em relação à baseline E01, mantendo todas as outras variáveis (seed 42, split, normalização, épocas, otimizador) rigorosamente idênticas.

5. Comparação E01 vs E02: Número de Neurónios (Largura)

Variando a largura de 8 para 16 neurónios por camada (E02), os parâmetros triplicaram de 105 para 337 (+221%). A accuracy subiu de 98.40% para 99.20% (+0.80 pp) e a loss caiu para 0.0278. Conclusão: a rede maior opera com maior confiança estatística, embora a accuracy atinja retornos decrescentes devido à simplicidade do dataset.

6. Comparação E01 vs E03: Número de Camadas (Profundidade)

Reduzindo a profundidade de 2 camadas para 1 camada oculta (E03), os parâmetros caíram para 33 (-68.6%). Contudo, a accuracy caiu para 88.00% (-10.40 pp) e a loss subiu para 0.2300. Conclusão: com apenas 8 neurónios, 1 camada tem flexibilidade geométrica insuficiente para moldar a fronteira em espiral das meias-luas; a composição de não-linearidades em profundidade foi fundamental.

7. Comparação E01 vs E04: Função de Ativação (tanh vs ReLU)

Mantendo 105 parâmetros e trocando tanh por ReLU (E04), a accuracy foi de 94.40% e loss 0.1522. Conclusão: a ativação tanh (suave e centrada em zero) obteve desempenho superior e convergência mais estável nesta arquitetura pequena. A ReLU apresentou oscilações na curva de treino decorrentes do desligamento temporário de unidades ('dying ReLU') em rede rasa.

8. Comparação E01 vs E05: Base de Dados (moons vs circles)

Aplicando a arquitetura baseline ao dataset `make_circles` (E05), a accuracy foi de 62.40% e loss 0.6668. Conclusão: com ruído 0.15 e fator 0.8, os dois anéis concêntricos (raios 0.8 e 1.0) sobrepõem-se fisicamente no espaço de entrada. A loss próxima de $\ln(2) \approx 0.693$ comprova a incerteza intrínseca dos dados e evidencia que o desempenho depende fortemente da separabilidade geométrica da base.

9. Tabela Consolidada de Resultados (E01 a E05)

Resultados gerados automaticamente a partir do ficheiro resultados.csv:

Exp.	Dataset	Camadas	Neurónios	Ativação	Parâmetros	Accuracy	Loss
E01	make_moons	2	8	tanh	105	98.40%	0.0853
E02	make_moons	2	16	tanh	337	99.20%	0.0278
E03	make_moons	1	8	tanh	33	88.00%	0.2300
E04	make_moons	2	8	relu	105	94.40%	0.1522
E05	make_circles	2	8	tanh	105	62.40%	0.6668

10. Fronteiras de Decisão (E01 e E05)

Visualização da probabilidade prevista e da linha de decisão (limiar 0.5) gerada pelo contrato visualizacao.py:




Figura 1: Fronteira E01 (make_moons - 98.4%)




Figura 2: Fronteira E05 (make_circles - 62.4%)

11. Curvas de Loss de Treino (E01 vs E04)




Figura 3: Curvas de loss ao longo das 100 épocas: tanh (E01) vs ReLU (E04)

12. Limitações Metodológicas

Em conformidade com as boas práticas científicas, reconhecem-se as seguintes limitações:

- Amostragem de Hiperparâmetros: cinco experiências não esgotam o espaço de configurações possíveis nem permitem extrapolar superioridade universal de uma função ou topologia.
- Variabilidade e Seed Única: a seed fixa (42) permite reprodutibilidade exata, mas não estima o intervalo de confiança nem a variância entre diferentes inicializações aleatórias.
- Métricas de Avaliação: em datasets balanceados (50/50), accuracy e loss são informativas, mas em dados desbalanceados exigiriam precisão, recall e curva ROC/AUC.
- Datasets Sintéticos: bases 2D facilitam a visualização mas não representam a dimensionalidade, ruído heterogêneo e correlações complexas de problemas industriais reais.

13. Contribuições da Equipa

Membro	Responsabilidade Principal	Entregáveis Realizados
Helton Soares	Fundação e Baseline (NNPROJ-5, 8, 11)	Contratos de software (contratos.py), pipeline de dados (dados.py), execução e consolidação CSV E01 a E05.
Luciana Almeida	Neurónios e Ativações (NNPROJ-4, 7)	Validação experimental E02 (16 neurónios) e E04 (ReLU), análise da convergência das ativações e conclusões técnicas.
Pedro Rodrigues	Topologias, Visualização e Relatório (NNPROJ-6, 9, 12)	Módulo de visualização (visualizacao.py), geração das fronteiras e curvas, análise de camadas (E03) e relatório final.
Daniela Amaro	Revisão Geral e Qualidade (Controlos 1 a 5)	Auditoria dos contratos técnicos, validação da baseline, conformidade das experiências e aprovação formal dos PRs.

Aprovação Final da Revisora: Relatório conferido e aprovado formalmente em 17/09/2026. Todos os valores correspondem aos ficheiros de dados e o código é 100% auditável e reproduzível.