

# RELATÓRIO FINAL DE EXPERIÊNCIAS — REDES NEURAIS

Neural Network Moon Project • Task NNPROJ-12 • Data: 17/09/2026  
Colaboradores: Daniela Amaro, Helton Soares, Luciana Almeida, Pedro Rodrigues

## 1. Objetivo do Projeto

O objetivo central deste trabalho não é encontrar a melhor arquitetura de rede neural possível, mas sim realizar um estudo científico controlado sobre como alterações estruturais e de dados afetam o processo de aprendizagem e a capacidade de generalização de uma rede neural artificial em problemas de classificação binária não linearmente separáveis.

## 2. Problema de Classificação Binária

Classificação binária consiste em prever uma entre duas classes possíveis (0 ou 1) a partir de atributos de entrada (duas coordenadas  $(x_1, x_2)$ ). Foram utilizados dois conjuntos sintéticos:

- `make_moons`: 500 amostras formando duas meias-luas entrelaçadas (ruído 0.15).
- `make_circles`: 500 amostras formando dois círculos concêntricos (ruído 0.15, fator padrão 0.8).

Ambos os padrões são não lineares: não é possível separar as classes por uma única reta, exigindo redes com camadas ocultas e funções de ativação não lineares.

## 3. Descrição da Baseline E01

A baseline E01 adota 2 camadas ocultas com 8 neurónios cada, ativação `tanh`, saída `sigmoid`, otimizador `Adam`, `loss binary_crossentropy`, 100 épocas e `batch size 16`. O `split` é 75% treino (375 amostras) e 25% teste (125 amostras), com `StandardScaler` ajustado exclusivamente no conjunto de treino. Atingiu `accuracy` de 98.40% e `loss` de 0.0853 com 105 parâmetros.

## 4. Regra Científica: 'Uma Variável de Cada Vez'

Para garantir validade causal, cada experiência subsequente (E02 a E05) altera exatamente um único elemento em relação à baseline E01, mantendo todas as outras variáveis (`seed 42`, `split`, normalização, épocas, otimizador) rigorosamente idênticas.

## 5. Comparação E01 vs E02: Número de Neurónios (Largura)

Variando a largura de 8 para 16 neurónios por camada (E02), os parâmetros triplicaram de 105 para 337 (+221%). A `accuracy` subiu de 98.40% para 99.20% (+0.80 pp) e a `loss` caiu para 0.0278. Conclusão: a rede maior opera com maior confiança estatística, embora a `accuracy` atinja retornos decrescentes devido à simplicidade do dataset.

## 6. Comparação E01 vs E03: Número de Camadas (Profundidade)

Reduzindo a profundidade de 2 camadas para 1 camada oculta (E03), os parâmetros caíram para 33 (-68.6%). Contudo, a `accuracy` caiu para 88.00% (-10.40 pp) e a `loss` subiu para 0.2300. Conclusão: com apenas 8 neurónios, 1 camada tem flexibilidade geométrica insuficiente para moldar a fronteira em espiral das meias-luas; a composição de não-linearidades em profundidade foi fundamental.

## 7. Comparação E01 vs E04: Função de Ativação (tanh vs ReLU)

Mantendo 105 parâmetros e trocando `tanh` por `ReLU` (E04), a `accuracy` foi de 94.40% e `loss` 0.1522. Conclusão: a ativação `tanh` (suave e centrada em zero) obteve desempenho superior e convergência mais estável nesta arquitetura pequena. A `ReLU` apresentou oscilações na curva de treino decorrentes do desligamento temporário de unidades ('dying ReLU') em rede rasa.

## 8. Comparação E01 vs E05: Base de Dados (moons vs circles)

Aplicando a arquitetura baseline ao dataset `make_circles` (E05), a `accuracy` foi de 62.40% e `loss` 0.6668. Conclusão: com ruído 0.15 e fator 0.8, os dois anéis concêntricos (raios 0.8 e 1.0) sobrepõem-se fisicamente no espaço de entrada. A `loss` próxima de  $\ln(2) \approx 0.693$  comprova a incerteza intrínseca dos dados e evidencia que o desempenho depende fortemente da separabilidade geométrica da base.

## 9. Tabela Consolidada de Resultados (E01 a E05)

Resultados gerados automaticamente a partir do ficheiro resultados.csv:

| Exp. | Dataset      | Camadas | Neurónios | Ativação | Parâmetros | Accuracy | Loss   |
|------|--------------|---------|-----------|----------|------------|----------|--------|
| E01  | make_moons   | 2       | 8         | tanh     | 105        | 98.40%   | 0.0853 |
| E02  | make_moons   | 2       | 16        | tanh     | 337        | 99.20%   | 0.0278 |
| E03  | make_moons   | 1       | 8         | tanh     | 33         | 88.00%   | 0.2300 |
| E04  | make_moons   | 2       | 8         | relu     | 105        | 94.40%   | 0.1522 |
| E05  | make_circles | 2       | 8         | tanh     | 105        | 62.40%   | 0.6668 |

## 10. Fronteiras de Decisão (E01 e E05)

Visualização da probabilidade prevista e da linha de decisão (limiar 0.5) gerada pelo contrato visualizacao.py:




Figura 1: Fronteira E01 (make\_moons - 98.4%)




Figura 2: Fronteira E05 (make\_circles - 62.4%)

## 11. Curvas de Loss de Treino (E01 vs E04)




Figura 3: Curvas de loss ao longo das 100 épocas: tanh (E01) vs ReLU (E04)

## 12. Limitações Metodológicas

Em conformidade com as boas práticas científicas, reconhecem-se as seguintes limitações:

- Amostragem de Hiperparâmetros: cinco experiências não esgotam o espaço de configurações possíveis nem permitem extrapolar superioridade universal de uma função ou topologia.
- Variabilidade e Seed Única: a seed fixa (42) permite reprodutibilidade exata, mas não estima o intervalo de confiança nem a variância entre diferentes inicializações aleatórias.
- Métricas de Avaliação: em datasets balanceados (50/50), accuracy e loss são informativas, mas em dados desbalanceados exigiriam precisão, recall e curva ROC/AUC.
- Datasets Sintéticos: bases 2D facilitam a visualização mas não representam a dimensionalidade, ruído heterogêneo e correlações complexas de problemas industriais reais.

## 13. Contribuições da Equipa

| Membro          | Responsabilidade Principal                             | Entregáveis Realizados                                                                                                 |
|-----------------|--------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| Helton Soares   | Fundação e Baseline (NNPROJ-5, 8, 11)                  | Contratos de software (contratos.py), pipeline de dados (dados.py), execução e consolidação CSV E01 a E05.             |
| Luciana Almeida | Neurónios e Ativações (NNPROJ-4, 7)                    | Validação experimental E02 (16 neurónios) e E04 (ReLU), análise da convergência das ativações e conclusões técnicas.   |
| Pedro Rodrigues | Topologias, Visualização e Relatório (NNPROJ-6, 9, 12) | Módulo de visualização (visualizacao.py), geração das fronteiras e curvas, análise de camadas (E03) e relatório final. |
| Daniela Amaro   | Revisão Geral e Qualidade (Controlos 1 a 5)            | Auditoria dos contratos técnicos, validação da baseline, conformidade das experiências e aprovação formal dos PRs.     |